

BREATHE BARCELONA

URBAN AIR QUALITY INTELLIGENCE

Análisis espacio-temporal de la calidad del aire,
movilidad y entorno urbano

OPEN DATA

SPACE + TIME

MODELS

PRODUCT



DATOS ABIERTOS → EVIDENCIA → MODELOS → PRODUCTO

Un sistema reproducible que conecta evolución temporal, estructura territorial, validación, interpretabilidad y predicción interactiva.

Máster en Data Science, Big Data & Business Analytics

Susana Fugarolas Álvarez-Ude · Septiembre de 2026

Índice de contenidos

Sección	Contenido	Página
1	Resumen ejecutivo	1
2	Problema, objetivos y aportación	1
3	Datos abiertos: el activo central del proyecto	2
4	Por qué NO ₂ y cómo se construye el criterio de clasificación	5
5	Análisis exploratorio: entender antes de predecir	6
6	Clasificación temporal de NO ₂ con XGBoost	7
7	Series temporales: de la clasificación a la concentración continua	9
8	Construcción de la dimensión espacial	10
9	Integración: una lectura espacio-temporal del NO ₂	15
10	Breathe Barcelona: del análisis a un producto utilizable	16
11	Discusión, limitaciones y trabajo futuro	18
12	Conclusiones, referencias y trazabilidad	19

REPOSITORIO Y MATERIALES REPRODUCIBLES

Código, notebooks técnicos y documentación: github.com/sfugalvude/breathe-barcelona

Complementa los anexos entregados y facilita la trazabilidad y reproducibilidad del trabajo.

CÓMO LEER ESTA MEMORIA

El hilo conductor es deliberadamente simple: datos abiertos → construcción de información comparable → elección del NO₂ → modelización temporal y espacial → interpretación → producto interactivo. Cada técnica aparece porque responde a una propiedad observada en los datos, no por acumular algoritmos.

1 · Resumen ejecutivo

Breathe Barcelona es una solución de analítica avanzada diseñada para estudiar la calidad del aire de Barcelona desde dos dimensiones que normalmente se analizan por separado: cuándo cambia la contaminación y dónde se concentra.

La aportación combina técnicas elegidas según la estructura del problema: SARIMA/SARIMAX para dinámica temporal, XGBoost para clasificación multiclase, LISA/Moran bivariado y regresión espacial para dependencia territorial, y SHAP para interpretación. La validación utiliza TEST cronológico 2024, rolling one-step-ahead, Leave-One-Station-Out y diagnóstico de residuos.

El NO₂ se adopta como contaminante principal por su cobertura, variabilidad temporal y espacial y vínculo con fuentes urbanas. PM10, PM2.5 y O₃ se mantienen como contexto; PM10 y PM2.5 se modelizan además en series temporales

Resultado	Valor	Lectura
Clasificación NO ₂ · TEST 2024	Accuracy 0,8867 · F1 macro 0,7476	Buen rendimiento global; la clase Mala sigue siendo el reto
Series temporales	-12,46 % RMSE vs Naive en NO ₂	La historia y el contexto mejoran la predicción rolling
Estructura espacial	LISA: 412 significativas · HH=189 · LL=210	Existen agrupaciones espaciales locales significativas
Modelo SAR	R ² = 0,8112 · MAE = 1,6340	La dependencia espacial explica una parte sustancial del patrón

Producto final · Los resultados se materializan en Breathe Barcelona, una aplicación interactiva que integra Overview, Temporal, Spatial, Model Insights y Dual Predictor. La aplicación consume outputs persistentes y permite explorar evidencia e inferencia sin reentrenar durante la navegación.

2 · Problema, objetivos y aportación

2.1 · Problema

La contaminación urbana depende de emisiones, movilidad, meteorología y configuración territorial. El problema no puede reducirse a una relación simple entre tráfico y concentración. La concentración observada combina presión emisora, dispersión atmosférica, persistencia temporal y configuración territorial.



Figura 1. Marco conceptual del problema de contaminación urbana y dimensiones consideradas.

Barcelona ofrece numerosas fuentes públicas con escalas y frecuencias distintas. El reto consiste en integrar contaminación, aforos, meteorología, ruido, tráfico aéreo, actividad marítima y capas territoriales en unidades analíticas compatibles.

2.2 · Objetivo general

Desarrollar una solución reproducible que integre datos urbanos heterogéneos y permita caracterizar, explicar y predecir patrones de calidad del aire en Barcelona, conectando dimensión temporal, dimensión espacial e interacción con el usuario.

El alcance es observacional y predictivo: el proyecto integra señales ambientales y urbanas, detecta patrones y evalúa capacidad predictiva, sin sustituir la vigilancia oficial ni atribuir causalidad a políticas concretas.

2.3 · Preguntas de investigación

Pregunta	Dimensión	Respuesta analítica
¿Cuándo cambia la contaminación?	Temporal	EDA, clasificación, SARIMA/SARIMAX y análisis COVID
¿Dónde se concentra?	Espacial	Cartografía, LISA, Moran bivariado y SAR
¿Qué condiciones aportan información?	Interpretación	SHAP, covariables y Moran bivariado
¿Generaliza?	Validación	TEST 2024, rolling y LOSO
¿Cómo se convierte en producto?	Explotación	Breathe Barcelona

2.4 · Aportaciones

- Integración reproducible de fuentes abiertas heterogéneas en bases listas para análisis.
- Doble lectura temporal: clasificación de categorías y predicción continua.
- Modelización explícita de la dependencia espacial y comparación complementaria con ML no lineal.
- Validación diseñada para respetar cronología y transferencia entre estaciones.
- Productivización de resultados en una aplicación interactiva, desacoplada del entrenamiento.

3 · Datos abiertos: el activo central del proyecto

La adquisición y preprocesamiento temporal se documentan en el ANEXO_1_LF_01_ETL_Preprocesamiento_Fuentes.ipynb; la integración y construcción del dataset maestro, en el ANEXO_2_LF_02_ETL_Integracion_Dataset_Maestro.ipynb.

El ETL integra fuentes públicas heterogéneas y resuelve diferencias de formato, identificadores, frecuencia, cobertura y geometría antes de la modelización.



Figura 2. Síntesis de tratamientos aplicados a cada familia de fuentes antes de construir las bases maestras.

El proyecto utiliza datos abiertos de portales públicos oficiales. Se revisan procedencia, condiciones de acceso/reutilización y trazabilidad; no se emplean datos de empresa ni información confidencial. Esta elección favorece reproducibilidad y transferencia a otras ciudades.

Open Data BCN — Ayuntamiento de Barcelona constituye una de las principales fuentes del proyecto (opendata-ajuntament.barcelona.cat), aportando datos de calidad del aire, meteorología, tráfico rodado, ruido, tráfico aéreo y diversas capas geoespaciales y socioeconómicas. Estas fuentes combinan series temporales, datos puntuales, polígonos y superficies ráster.

La preparación es una fase analítica: se armonizan cambios históricos, estaciones y frecuencias; se agregan registros de alta frecuencia y se compatibilizan capas vectoriales, ráster y administrativas.

Bloque	Fuente/dataset	Uso en el TFM
Contaminación	Open Data BCN · Qualitat de l'aire	Objetivo, EDA y variables ambientales
Meteorología	Open Data BCN · Mesures estacions meteorològiques	Contexto temporal y covariables
Tráfico rodado	Open Data BCN · Aforaments de trànsit	Actividad urbana e influencia de proximidad
Ruido	Open Data BCN · Xarxa de Soroll	Proxy de actividad urbana
Tráfico aéreo	Open Data BCN · Trànsit aeri FlightRadar	Vuelos, zonas y compañías activas
Actividad marítima	Port de Barcelona Open Data	Llegadas, salidas y movimientos marítimos
Territorio y socioeconomía	Open Data BCN · inmisión, unidades, usos, densidad y renta	Estructura geoespacial y contexto territorial
Topografía	CNIG/IGN · MDT200 – 1.ª cobertura	Elevación y contexto físico del territorio

Reproducibilidad · Los enlaces de origen y la cobertura de cada fuente se documentan en los notebooks LF_01 temporal y LF_01 geoespacial. Los notebooks LF_02 realizan la integración y las auditorías de consistencia de los datasets maestros.

El maestro temporal alcanza 43.642 observaciones y 73 variables entre 12/06/2018 y 31/12/2024. La clasificación de NO₂ utiliza 2019–2024 para evitar la cobertura parcial de 2018. La rama espacial contiene 1.068 secciones censales válidas en EPSG:25831.



Figura 3. Granularidades de origen y proceso de integración. La homogeneización produce dos bases diferenciadas: un maestro temporal y una base territorial, cada una coherente con su unidad de análisis.

3.1 · Ayuntamiento de Barcelona: de múltiples portales a un dataset analítico

La calidad del aire se transforma desde registros por fecha, estación y contaminante a una estructura diaria y trazable. El ETL normaliza identificadores y agrega NO₂, O₃, PM10 y PM2.5 por fecha y estación geográfica, conservando controles de calidad y coherencia temporal.

La meteorología se integra diariamente mediante temperatura, humedad, presión, precipitación, radiación y viento.

La rama geoespacial utiliza además información territorial que no cambia diariamente: densidad de población, renta disponible, usos del suelo y elevación derivada del Modelo Digital del Terreno MDT200, distribuido por el Centro Nacional de Información Geográfica (CNIG) del Instituto Geográfico Nacional (IGN). Estas variables describen contexto urbano y se tratan explícitamente como covariables espaciales estáticas dentro del periodo analizado.

La decisión de trabajar con fuentes oficiales abiertas aporta una ventaja adicional: cada transformación puede rastrearse hasta el origen.

El reto no es descargar recursos aislados, sino hacer interoperables datasets con estructuras, coberturas y cambios históricos distintos; por ello se auditan fechas, estaciones, unidades y granularidad.

Fuente oficial	URL documentada en los notebooks
Calidad del aire	https://opendata-ajuntament.barcelona.cat/data/es/dataset/qualitat-aire-detall-bcn
Aforos de tráfico	https://opendata-ajuntament.barcelona.cat/data/es/dataset/aforaments-detall
Meteorología	https://opendata-ajuntament.barcelona.cat/data/es/dataset/mesures-estacions-meteorologiques
Ruido	https://opendata-ajuntament.barcelona.cat/data/es/dataset/xarxasoroll-equipmonitor-dades
Mapas de inmisión de calidad del aire	https://opendata-ajuntament.barcelona.cat/data/es/dataset/mapes-immissio-qualitat-aire
Tráfico aéreo	https://opendata-ajuntament.barcelona.cat/data/es/dataset/transitaeri_flightradar_ppal_aeroport

Criterio de integración · No se fuerza una falsa homogeneidad entre fuentes. Cada variable se transforma según su naturaleza y después se integra a la resolución de la rama correspondiente. El objetivo es conservar significado físico y evitar que una operación de unión genere precisión aparente que la fuente original no posee.

3.2 · Integración multifuente y arquitectura analítica

La rama temporal integra seis familias de información con granularidades de origen diferentes: contaminación atmosférica, meteorología, tráfico rodado, ruido, tráfico aéreo y actividad marítima. Cada fuente se transforma respetando su resolución y cobertura antes de incorporarse al maestro temporal; los huecos estructurales de cobertura, especialmente en la serie aérea, se conservan explícitamente y no se reconstruyen como observaciones reales.

En paralelo, la rama espacial construye una base territorial sobre 1.068 secciones censales mediante mapas de inmisión, aforos y distancia al tráfico, renta, densidad, usos del suelo y elevación. La topografía procede del MDT200 del CNIG/IGN. Esta rama resume contexto territorial agregado y no pretende reproducir la variación diaria de las estaciones.

Ambas ramas convergen posteriormente en los modelos y en Breathe Barcelona, pero mantienen unidades de análisis distintas: fecha × estación × contaminante en la dimensión temporal y sección censal en la dimensión espacial.




Figura 4. Arquitectura de integración: de fuentes abiertas heterogéneas a modelos y producto interactivo.

Trazabilidad técnica · ANEXO_1_LF_01_ETL_Preprocesamiento_Fuentes.ipynb documenta el ETL y control de calidad de las seis fuentes temporales; ANEXO_2_LF_02_ETL_Integracion_Dataset_Maestro.ipynb construye y audita el maestro temporal. ANEXO_5_LF_01_Preprocesado_Fuentes_Geospaciales.ipynb prepara las fuentes territoriales —incluido el MDT200 del CNIG/IGN— y ANEXO_6_LF_02_Integración_y_análisis_geoespacial.ipynb realiza la integración, diagnóstico y modelización espacial. Esta separación permite auditar cada transformación sin mezclarla con el entrenamiento de modelos.

La construcción del target, las comprobaciones de consistencia y el desarrollo completo del problema de clasificación se recogen en ANEXO_3_LF_03_Modelo_Temporal_Clasificacion_NO2.ipynb.

4 · Por qué NO₂ y cómo se construye el criterio de clasificación

El NO₂ se adopta como hilo conductor por su cobertura 2019–2024, variabilidad temporal y territorial y relación con movilidad, meteorología y fuentes urbanas.

PM10 y PM2.5 se mantienen en el análisis y se modelizan en series temporales, pero PM2.5 presenta una cobertura más limitada. O₃ aporta información ambiental relevante, aunque su dinámica fotoquímica y su relación con precursores hacen que responda a una lógica distinta.



Figura 5. Conversión de la concentración diaria de NO₂ en el target multiclase utilizado por LF_03. El criterio conserva el NO₂ continuo para EDA y series temporales y crea una etiqueta específica para clasificación.

El clasificador utiliza tres categorías operativas: Buena (≤25 µg/m³), Media (>25 y ≤60 µg/m³) y Mala (>60 µg/m³). El umbral de 25 µg/m³ coincide con la guía OMS 2021 para NO₂ a 24 horas.

La etiqueta se genera de forma determinista a partir de la concentración diaria y, una vez construida, el NO₂ contemporáneo se excluye de las variables predictoras. De esta forma el modelo debe inferir la clase mediante historia previa, meteorología, movilidad y contexto, evitando una fuga directa de la variable que define el target.

En las 14.022 observaciones con target válido, la distribución es 57,62 % Buena, 40,51 % Media y 1,88 % Mala. El fuerte desequilibrio explica por qué la accuracy no puede ser la única métrica y por qué el entrenamiento incorpora SMOTE dentro del flujo de entrenamiento.

Precaución interpretativa · Las categorías son una discretización útil de una variable continua. La memoria conserva también NO₂ en µg/m³ para EDA, series temporales y análisis espacial; así se evita perder información por depender exclusivamente del target categórico.

5 · Análisis exploratorio: entender antes de predecir

El análisis exploratorio confirma diferencias entre estaciones, fuerte desequilibrio de clases y persistencia temporal. Estos hallazgos justifican LOSO, el uso de F1 macro y balanced accuracy junto a accuracy, y la incorporación de variables rezagadas y modelos temporales.

El EDA se diseña para identificar estructura, no únicamente para describir medias. La evolución temporal muestra cambios entre 2019, el periodo COVID 2020–2021 y 2022–2024. La proporción de observaciones clasificadas como Buena pasa del 35,66 % en el periodo pre-COVID al 59,98 % durante COVID y se mantiene en 60,62 % en el periodo post-COVID.

Las estaciones presentan perfiles distintos. Eixample registra la mayor media de NO₂ (37,60 µg/m³), seguida de Gràcia (32,03) y Ciutadella (26,77); Sants alcanza 24,87. Esta heterogeneidad justifica Leave-One-Station-Out para medir transferencia a estaciones no vistas.

Los análisis bivariantes frente a tráfico, ruido, vuelos y actividad portuaria muestran dispersión elevada. Esta ausencia de una relación lineal simple no invalida las variables: al contrario, refuerza el planteamiento multivariable.

El EDA detecta además memoria temporal: la autocorrelación disminuye con el retardo, pero permanece apreciable durante varios días.




Figura 6. EDA del NO₂: (a) concentración media por estación y (b) distribución del target Buena/Media/Mala. La heterogeneidad espacial convive con un fuerte desequilibrio de clases. Fuente: ANEXO_3_LF_03_Modelo_Temporal_Clasificacion_NO2.ipynb.

Lectura del dashboard · La vista temporal no afirma causalidad a partir de correlaciones. Presenta evolución, asociación exploratoria, predicción y explicación del modelo en paneles separados para que el usuario distinga descripción, predicción e interpretación.

El pipeline reproducible de ingeniería de variables, separación temporal, preprocesado, SMOTE, comparación de modelos, evaluación de 2024, SHAP y validación Leave-One-Station-Out se encuentra en el ANEXO_3_LF_03_Modelo_Temporal_Clasificacion_NO2.ipynb.

6 · Clasificación temporal de NO₂ con XGBoost

La comparación entre modelos se interpreta desde el equilibrio entre rendimiento global y comportamiento por clase. El XGBoost + SMOTE obtiene 0,8867 de accuracy y 0,7476 de F1 macro en 2024. En la matriz de confusión, 8 de los 22 episodios Mala se identifican correctamente; 14 se desplazan a Media.



Figura 7. Estrategias de validación asociadas a cada riesgo metodológico del proyecto.

El clasificador predice la categoría diaria de NO₂ por fecha y estación. Utiliza historia del contaminante, meteorología, tráfico y contexto urbano, excluyendo la concentración contemporánea y variables derivadas directamente del target para evitar leakage.

El feature engineering temporal incorpora retardos y ventanas móviles. Esta decisión se apoya en la persistencia observada: la misma categoría se mantiene de un día al siguiente en el 76,34 % de los casos. Buena presenta una persistencia del 81,80 %, Media del 70,66 % y Mala del 29,92 %.

La separación de entrenamiento y prueba es cronológica: 2019–2023 se utiliza para desarrollar el modelo y 2024 se reserva como TEST. La Figura 8 resume la lógica metodológica común del proyecto: primero se diagnostica la propiedad del dato, después se selecciona la técnica y finalmente se valida e interpreta.

El balanceo mediante SMOTE se restringe al conjunto de entrenamiento. El objetivo es mejorar el aprendizaje de la clase minoritaria sin alterar la distribución real del periodo de evaluación. Por ese motivo la lectura se apoya en accuracy, balanced accuracy y F1 macro, y no únicamente en la tasa global de acierto.



Figura 8. Principio metodológico común: diagnóstico → técnica → validación → interpretación → explotación. Cada técnica responde a una propiedad previamente observada en los datos.

Métrica · TEST 2024	Resultado
Accuracy	0,8867
Balanced accuracy	0,7019
F1 macro	0,7476
F1 weighted	0,8853
ROC-AUC macro	0,9637

Por qué varias métricas · La accuracy refleja el rendimiento global, pero la balanced accuracy y el F1 macro penalizan que el modelo funcione bien solo en la clase mayoritaria. En un problema con apenas 1,88 % de observaciones Mala, esta lectura múltiple es imprescindible.

6.1 · Errores, interpretabilidad y generalización espacial

La matriz de confusión del TEST 2024 muestra un comportamiento desigual por clase. Buena alcanza un recall del 92,9 %; Media, 81,4 %; y Mala, 36,4 %. La clase adversa es por tanto el principal punto débil.

SHAP identifica las variables que más contribuyen a las predicciones. Para la clase Mala destacan O₃, NO₂ lag 1 día, PM10, viento medio y medias móviles de NO₂. Estas importancias explican el modelo, pero no representan efectos causales.




Figura 9. Importancia SHAP específica para la clase Mala. O₃, NO₂ lag 1, PM10, viento y medias móviles de NO₂ concentran parte relevante de la señal predictiva. Fuente: ANEXO_3_LF_03_Modelo_Temporal_Clasificacion_NO2.ipynb.

LOSO excluye cada estación del entrenamiento y evalúa sobre ella. El F1 macro medio es 0,6497, inferior al TEST temporal, lo que confirma que transferir el modelo a una estación no observada es más difícil.




Figura 10. Evaluación del clasificador XGBoost + SMOTE: matriz de confusión sobre 2024 y generalización Leave-One-Station-Out. Fuente: ANEXO_3_LF_03_Modelo_Temporal_Clasificacion_NO2.ipynb.

El desarrollo completo de las series, baselines, diagnóstico ACF/PACF, ajuste SARIMA/SARIMAX y validación rolling one-step-ahead se incorpora como ANEXO_4_LF_04_Modelos_Series_Temporales.ipynb.

Ámbito de validez · El modelo es sólido como clasificador temporal dentro del dominio observado, pero la generalización espacial es heterogénea. La memoria distingue ambas capacidades en lugar de resumirlas en una única cifra.

7 · Series temporales: de la clasificación a la concentración continua

La segunda rama temporal trabaja directamente con concentraciones continuas de NO₂, PM10 y PM2.5. El objetivo cambia: ya no se trata de asignar una categoría, sino de anticipar la concentración a corto plazo representando explícitamente memoria, estacionalidad y covariables.

NO₂ y PM10 se modelizan principalmente sobre 2020–2024 por homogeneidad de cobertura. PM2.5 dispone de una serie más corta y espacialmente limitada, por lo que se trabaja con Palau Reial como referencia. Los tests ADF rechazan raíz unitaria en los tres contaminantes y se trabaja en niveles ($d=0$). La Figura 11 muestra la estructura de autocorrelación que motiva el uso de SARIMA/SARIMAX.




Figura 11. ACF y PACF del NO₂ diario. La dependencia en retardos cortos y la señal semanal orientan la elección de componentes autorregresivos y estacionales. Fuente: ANEXO_4_LF_04_Modelos_Series_Temporales.ipynb.

El benchmark es deliberadamente simple: persistencia Naive $t-1$. Un modelo complejo solo aporta valor si mejora una predicción elemental basada en el último valor observado. También se considera la referencia estacional $t-7$ cuando procede.

Esta comparación es importante porque una serie persistente puede generar métricas aparentemente buenas sin aportar capacidad real frente al último valor observado. Superar Naive permite demostrar que la estructura temporal y las covariables añaden información.

Contaminante	ADF p	Decisión
NO ₂	0,000030	Trabajar en niveles · $d=0$
PM10	≈ 0	Trabajar en niveles · $d=0$
PM2.5	≈ 0	Trabajar en niveles · $d=0$

Lección metodológica · La primera evaluación recursiva de horizontes largos mostró pérdida de precisión. En lugar de descartarla, se utiliza para demostrar que el esquema de validación es parte del problema. La comparación final adopta rolling one-step-ahead, coherente con una actualización secuencial de observaciones.

7.1 · SARIMA/SARIMAX y validación rolling

Frente a Naive, SARIMAX reduce RMSE un 12,46 % en NO₂ (RMSE 6,843; R^2 0,396), un 14,06 % en PM10 (RMSE 6,501) y un 12,78 % en PM2.5 (RMSE 3,465; R^2 0,537).

SARIMA representa la dependencia interna de la serie y SARIMAX añade covariables. La evaluación rolling de 2024 actualiza secuencialmente el modelo y compara cada predicción con el valor observado.

Contaminante	Modelo final	Covariables	RMSE	R²	Mejora RMSE vs Naive
NO ₂	SARIMAX	Tráfico	6,843	0,396	12,46 %
PM10	SARIMAX	Meteo + tráfico	6,501	0,282	14,06 %
PM2.5	SARIMAX	Meteorología	3,465	0,537	12,78 %

La mejora frente a persistencia es moderada pero consistente. Los modelos reducen error frente al baseline, aunque tienden a suavizar episodios extremos, limitación relevante para posibles sistemas de alerta.

La validación rolling actualiza el estado del modelo paso a paso y compara todos los métodos sobre las mismas fechas.




Figura 12. NO₂ observado frente a Naive t-1, SARIMA y SARIMAX + tráfico durante 2024. La comparación rolling muestra seguimiento de la dinámica diaria y dificultad en algunos picos. Fuente: ANEXO_4_LF_04_Modelos_Series_Temporales.ipynb.

SARIMAX rolling utiliza covariables contemporáneas conocidas. Por tanto, un despliegue de forecast futuro real exigiría disponer también de predicciones o escenarios para esas entradas. Esta condición se explicita para no presentar el experimento como si ya resolviera por sí solo una predicción operacional multihorizonte.

La preparación de cartografía, MDT, usos del suelo, aforos y variables socioeconómicas, junto con las operaciones espaciales necesarias para obtener la unidad de análisis por sección censal, se documenta en el ANEXO_5_LF_01_Preprocesado_Fuentes_Geospaciales.ipynb.

El análisis COVID se utiliza como contexto descriptivo. La media de NO₂ post-COVID es solo un 0,81 % inferior a la media del periodo COVID en la agregación considerada, mientras PM10 aumenta un 5,41 %.

Resultado clave · Para NO₂, el SARIMAX rolling obtiene RMSE 6,843, MAE 5,24 y R² ≈0,40 en 2024, con una mejora de RMSE del 12,46 % frente al baseline Naive.

8 · Construcción de la dimensión espacial

La rama espacial estudia cómo se distribuye territorialmente el NO₂ en 1.068 secciones censales. Las capas se armonizan en EPSG:25831 e integran contaminación, movilidad, renta, densidad, elevación y usos del suelo.

Los mapas anuales de contaminación por tramo viario se transforman en valores numéricos a partir de sus intervalos. La elevación procede de un MDT de 200 × 200 m. La asignación espacial presenta una distancia máxima de 138,87 m, inferior a la distancia teórica centro-esquina de una celda de 200 m (141,42 m), lo que aporta una comprobación geométrica sencilla de consistencia.

El cálculo reproducible de Moran Local (LISA), Moran bivariado, matriz de pesos, significación por permutaciones y cartografía de clusters se desarrolla en el ANEXO_6_LF_02_Integración_y_análisis_geoespacial.ipynb. La memoria conserva aquí la interpretación sustantiva de esos resultados.




Figura 13. Evolución espacial del NO₂ en la cartografía de tramos viarios para años representativos. La intensidad varía, pero persiste una heterogeneidad territorial clara. Fuente: ANEXO_5_LF_01_Preprocesado_Fuentes_Geospaciales.ipynb.

Variable final	Familia
IMD_AFORO_CERCANO	Movilidad
DISTANCIA_AFORO_M	Movilidad / posición
RENTA_EUR_PERSONA	Socioeconomía
DENSIDAD_HAB_HA	Socioeconomía
ELEVACION_MEDIA_M	Topografía
PCT_VERDE	Uso del suelo
PCT_EQUIPAMIENTOS	Uso del suelo
PCT_INDUSTRIAL / PORTUARIO / TRANSPORTE	Uso del suelo

Naturaleza de la rama espacial · El dataset espacial resume contexto territorial; no pretende reproducir la variación diaria de cada sección. Por eso sus resultados deben interpretarse como estructura espacial agregada, complementaria a la rama temporal de estaciones.

8.1 · Autocorrelación: la ciudad no es un conjunto de observaciones independientes

El diagnóstico espacial justifica la regresión espacial: los cinco componentes PCA presentan Moran I positivo y significativo (0,3389–0,7554; p=0,001) y OLS deja autocorrelación residual elevada (I=0,6411; p=0,001).

Para el NO₂, la estructura local se estudia directamente mediante LISA sobre las 1.068 secciones censales, con matriz Queen estandarizada por filas y 999 permutaciones. Esta lectura permite localizar agrupaciones significativas y outliers espaciales sin atribuir causalidad a las covariables.

LISA (Local Indicators of Spatial Association) clasifica cada sección según su relación con las vecinas. En la versión definitiva de ANEXO_6_LF_02_Integración_y_análisis_geoespacial.ipynb se identifican 412 secciones significativas (p<0,05): 189 High-High (17,70 %), 210 Low-Low (19,66 %), 10 High-Low (0,94 %) y 3 Low-High (0,28 %); 656 secciones (61,42 %) no son significativas.


Patrones espaciales locales del NO₂ — LISA

Figura 14. Patrones espaciales locales del NO₂ mediante LISA. Los clusters High-High y Low-Low localizan agrupaciones significativas y las diferencian de outliers espaciales. Fuente: ANEXO_6_LF_02_Integración_y_análisis_geoespacial.ipynb.

La comparación OLS–SAR, el diagnóstico de dependencia espacial y la comprobación de autocorrelación residual se detallan en el ANEXO_6_LF_02_Integración_y_análisis_geoespacial.ipynb.

LISA localiza estructura espacial: High-High y Low-Low identifican agrupaciones de valores altos o bajos, mientras que High-Low y Low-High señalan outliers.



Figura 15. Lectura de los cuadrantes LISA y distribución final de patrones locales de NO₂ en 1.068 secciones.

Implicación · La fuerte autocorrelación espacial es una de las evidencias centrales del TFM. Si el NO₂ se organiza en clusters, una regresión clásica OLS puede dejar estructura espacial en los residuos y producir una lectura incompleta.

8.2 · De OLS a SAR: incorporar explícitamente la dependencia territorial

OLS se utiliza como baseline interpretable. Permite estudiar signos y significación de covariables, pero su papel principal es diagnóstico: comprobar si una regresión que asume independencia deja autocorrelación en los residuos. El entrenamiento del XGBoost espacial, su evaluación y la interpretación mediante SHAP, junto con Moran bivariado, se documentan íntegramente en el ANEXO_6_LF_02_Integración_y_análisis_geoespacial.ipynb.

Los diagnósticos espaciales justifican avanzar hacia un modelo Spatial Autoregressive (SAR), que incorpora explícitamente la dependencia entre unidades vecinas mediante un término espacial. El modelo alcanza $R^2=0,8112$, $RMSE=2,3464$ y $MAE=1,6340$. El parámetro rho es 0,850629, coherente con la fuerte estructura espacial detectada previamente.

La comprobación más importante no es únicamente el R^2 . El Moran de los residuos del SAR es $-0,0086$ y no resulta significativo ($p>0,05$): ya no se detecta autocorrelación espacial residual significativa. En términos metodológicos, el modelo ha absorbido la estructura territorial que OLS no podía representar adecuadamente.




Figura 16. Modelo SAR: NO₂ observado, predicción espacial y residuos. La ausencia de autocorrelación espacial residual significativa apoya la adecuación del modelo. Fuente: ANEXO_6_LF_02_Integración_y_análisis_geoespacial.ipynb.

Métrica SAR	Valor
R ²	0,8112
RMSE	2,3464
MAE	1,6340
Correlación observado-predicho	0,9027
Rho	0,850629
Moran residuos	-0,0086
p Moran residuos	>0,05

Lectura correcta · El R^2 del SAR no se compara como si fuera equivalente al R^2 test de XGBoost: los esquemas de estimación y evaluación son diferentes. SAR se utiliza sobre todo para representar y diagnosticar dependencia espacial; XGBoost aporta una lectura predictiva no lineal complementaria.

8.3 · XGBoost espacial, SHAP y convergencia entre métodos

El XGBoost espacial explora relaciones no lineales entre NO_2 medio y características territoriales. El baseline obtiene R^2 test 0,7147, RMSE 2,5820 y MAE 1,9570; la optimización apenas modifica el resultado (R^2 0,7153), lo que sugiere que el rendimiento no depende de una búsqueda agresiva de hiperparámetros.

SHAP sitúa elevación como variable principal (0,313), seguida de renta y distancia a aforo (0,187), densidad (0,139), IMD (0,090) y verde (0,031). Varias reaparecen en SAR, Moran biviado y SHAP.




Figura 17. Importancia global SHAP del XGBoost espacial. Elevación, renta, distancia al aforo, densidad e IMD concentran la mayor contribución predictiva. Fuente: ANEXO_6_LF_02_Integración_y_análisis_geoespacial.ipynb.

Moran biviado muestra asociaciones negativas para elevación (−0,4393), distancia a aforo (−0,3116) y verde (−0,2151), y positivas para densidad (0,2127) y renta (0,1676). Se interpretan como asociaciones, no causalidad.

Variable	Moran biviado	p	Lectura
Elevación	−0,4393	0,001	Asociación espacial negativa
Distancia aforo	−0,3116	0,001	Negativa
% verde	−0,2151	0,001	Negativa
Densidad	0,2127	0,001	Positiva
Renta	0,1676	0,001	Positiva
IMD aforo	−0,0709	0,006	Débil / negativa

Cautela · El split 80/20 de XGBoost espacial es aleatorio y no debe presentarse como validación espacial estricta. La memoria utiliza su test como estimación predictiva interna y reserva las afirmaciones sobre dependencia territorial a LISA, los diagnósticos de autocorrelación y SAR.

9 · Integración: una lectura espacio-temporal del NO₂

Los modelos aportan evidencias complementarias: clasificación temporal, mejora frente a persistencia, estructura espacial, regresión SAR e interpretación mediante SHAP. La fortaleza del proyecto reside en integrarlas sin confundir predicción, asociación y causalidad.



Figura 18. Lectura integrada de los principales resultados y de su significado analítico.

Los resultados de ambas ramas convergen en una idea: la calidad del aire de Barcelona no se entiende adecuadamente desde una única escala.

Seis notebooks analíticos forman la base reproducible; ANEXO_7_LF_01_Breathe_Barcelona_Dashboard.ipynb documenta la construcción y despliegue de Breathe Barcelona.

Las métricas no son directamente comparables porque cada modelo responde a una pregunta distinta: clasificación estación-día, predicción temporal continua, estructura territorial agregada o relaciones no lineales espaciales.

La fortaleza del resultado está precisamente en la complementariedad: el bloque temporal explica cuándo cambia la contaminación, el espacial localiza dónde se concentra y la interpretabilidad ayuda a identificar qué variables utiliza cada modelo para construir su predicción.

Pregunta	Evidencia principal	Implicación
¿Cuándo cambia?	XGBoost + SARIMAX	Historia reciente y contexto aportan capacidad predictiva
¿Dónde se concentra?	LISA: 412 significativas · HH=189 · LL=210	Existen clusters territoriales claros
¿Qué estructura aparece asociada?	SAR + SHAP + Moran bivariado	Dependencia espacial y contexto urbano son relevantes
¿Es robusto?	TEST 2024 + LOSO + residuos	Se cuantifican límites y estructura restante

El tráfico aéreo y la actividad marítima se interpretan como variables temporales de contexto; renta, densidad, elevación y usos del suelo caracterizan el contexto territorial. Estas variables amplían la lectura integrada, pero no permiten atribuir efectos causales aislados.



Figura 19. Convergencia de evidencias entre tiempo, territorio, predicción e interpretación. La recurrencia de señales entre métodos refuerza la lectura global, aunque no demuestra causalidad.

Aportación metodológica · El “modelo ganador” no es el objetivo. El resultado es una cadena de evidencia en la que cada técnica responde a una pregunta concreta y conserva sus propios límites de validación.

10 · Breathe Barcelona: del análisis a un producto utilizable

Seis notebooks generan los outputs que Breathe Barcelona organiza en Overview, Temporal, Spatial, Model Insights y Dual Predictor; ANEXO_7_LF_01_Breathe_Barcelona_Dashboard.ipynb documenta la integración.



Figura 20. Arquitectura de productivización: entrenamiento, persistencia de outputs, servicio e inferencia.

La portada resume Open Data → Space + Time → Models → Product. Overview sintetiza la ciudad; Temporal integra evolución, drivers y forecast; Spatial reúne LISA, SAR y Moran bivariado; Model Insights concentra métricas, SHAP y LOSO; y Dual Predictor explora escenarios dentro del dominio observado. La interfaz reproduce los resultados clave: NO₂ medio 24,5 µg/m³; SARIMAX 2024 RMSE 6,84 y mejora 12,5 % vs Naive; LISA 189 hotspots High-High; SAR R² 0,81; y clasificación TEST Accuracy 88,67 %, F1 macro 0,748 y LOSO F1 macro 0,650.




Figura 21. Breathe Barcelona, versión final: Overview, Temporal, Spatial y Model Insights. Las vistas consumen resultados persistidos de ANEXO_3_LF_03_Modelo_Temporal_Clasificacion_NO2.ipynb, ANEXO_4_LF_04_Modelos_Series_Temporales.ipynb y ANEXO_6_LF_02_Integración_y_análisis_geoespacial.ipynb y su integración se documenta en el Anexo 7; las métricas mostradas son redondeos de sus salidas reproducibles.

Productivización · El dashboard no es un añadido gráfico. Es la última capa de la arquitectura: transforma outputs técnicos en exploración, interpretación y escenarios. Esta materialización responde al objetivo del máster de aproximar el modelo a una aplicación empresarial.

10.1 · Dual Predictor y límites de uso

El Dual Predictor traduce la modelización a una interacción comprensible.

Restringir los controles al dominio observado es una decisión metodológica, no solo de interfaz. Evita extrapolaciones arbitrarias hacia combinaciones que el modelo nunca vio durante el entrenamiento.

En el escenario de la Figura 22, el predictor temporal devuelve Buena (54,5 %), Media (45,5 %) y Mala (0,0 %); el espacial estima 26,8 $\mu\text{g}/\text{m}^3$. Son resultados del escenario mostrado, no valores generales.




Figura 22. Dual Predictor final: inferencia espacial de NO₂ y clasificación temporal de calidad del aire. Los controles se restringen al dominio observado; los valores 26,8 $\mu\text{g}/\text{m}^3$ y Buena (54,5 %) corresponden únicamente a los escenarios mostrados. Fuente: ANEXO_7_LF_01_Breathe_Barcelona_Dashboard.ipynb.

11 · Discusión, limitaciones y trabajo futuro

Los modelos responden a preguntas diferentes: XGBoost clasifica episodios, SARIMAX evalúa predicción temporal, LISA localiza patrones, SAR modeliza dependencia territorial y SHAP explica contribución predictiva. El dashboard integra estas evidencias en una lectura conjunta.

Las principales limitaciones proceden de la naturaleza observacional y heterogénea de las fuentes: cobertura desigual, menor profundidad de PM2.5, proxies socioeconómicos estáticos y variables de actividad que no equivalen a emisiones directas.

Estas limitaciones se traducen en controles explícitos: SMOTE solo en TRAIN y métricas macro para el desequilibrio; LOSO para transferencia entre estaciones; baseline Naive y rolling para forecast; diagnóstico espacial antes y después de SAR; y restricciones del Predictor al dominio observado.



Figura 23. Riesgos metodológicos principales y controles incorporados en el pipeline.

Persisten límites: menor recall en Mala; LOSO peor que TEST temporal; SARIMAX rolling usa covariables conocidas y suaviza extremos; y XGBoost espacial usa split aleatorio, por lo que no constituye validación espacial estricta. Correlaciones, SHAP, coeficientes espaciales y Moran bivariado describen asociación o contribución predictiva, no causalidad. Un análisis causal de políticas urbanas exigiría variables de intervención, controles o diseños contrafactuales específicos.




Figura 24. Limitaciones principales y decisiones de control. Las limitaciones del dato se trasladan a reglas de validación, cautelas interpretativas y restricciones de uso.

11.1 · Trabajo futuro

- Automatizar la actualización de fuentes dinámicas de Open Data BCN y Port de Barcelona mediante APIs y controles de calidad, manteniendo trazabilidad separada para fuentes territoriales estáticas como el MDT200 del CNIG/IGN.
- Incorporar predicciones futuras de covariables para forecast multihorizonte real.
- Mejorar sensibilidad ante episodios extremos y explorar estrategias específicas para clases raras.
- Desarrollar validación espacial por bloques o particiones geográficas para el ML espacial.
- Integrar modelos espacio-temporales que conecten explícitamente estaciones, territorio y evolución diaria.
- Añadir inventarios de emisiones o variables portuarias más próximas a emisiones si estuvieran disponibles.

Lección principal · La validación y la trazabilidad importan tanto como el algoritmo. Un modelo complejo solo es útil cuando se conoce qué información utiliza, frente a qué baseline mejora y en qué dominio puede aplicarse.

12 · Conclusiones, referencias y trazabilidad

Breathe Barcelona demuestra que es posible construir una solución reproducible de analítica avanzada a partir de datos abiertos urbanos y convertirla en un producto interpretable.

- El clasificador temporal de NO₂ alcanza accuracy 0,8867 y F1 macro 0,7476 en TEST 2024; la clase Mala continúa siendo el principal reto.
- SARIMAX mejora el RMSE frente a persistencia en NO₂ (12,46 %), PM10 (14,06 %) y PM2.5 (12,78 %) bajo validación rolling.
- El análisis LISA del NO₂ identifica 412 secciones con asociación espacial local significativa: 189 High-High, 210 Low-Low, 10 High-Low y 3 Low-High; 656 secciones no resultan significativas.
- El modelo SAR alcanza $R^2=0,8112$, RMSE=2,3464 y MAE=1,6340, y deja residuos sin autocorrelación espacial significativa (Moran I=-0,0086; $p>0,05$).
- Elevación, distancia al aforo, densidad, renta e IMD reaparecen en varios enfoques, aunque su interpretación permanece asociativa.
- Breathe Barcelona integra exploración, explicación e inferencia en una aplicación interactiva desacoplada del entrenamiento.

Mensaje final · La aportación del proyecto no es un algoritmo aislado, sino una cadena reproducible de decisiones: abrir e integrar datos, diagnosticar estructura, seleccionar técnicas adecuadas, validar, interpretar límites y convertir los resultados en una herramienta utilizable.

Referencias bibliográficas y fuentes de datos

- Anselin, L. (1988). Spatial Econometrics: Methods and Models. Kluwer Academic Publishers. DOI: 10.1007/978-94-015-7799-1.
- Anselin, L. (1995). Local Indicators of Spatial Association—LISA. Geographical Analysis, 27(2), 93–115. DOI: 10.1111/j.1538-4632.1995.tb00338.x.
- Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2015). Time Series Analysis: Forecasting and Control (5th ed.). Wiley.
- Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic Minority Over-sampling Technique. Journal of Artificial Intelligence Research, 16, 321–357. DOI: 10.1613/jair.953.
- Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. Proceedings of KDD '16, 785–794. DOI: 10.1145/2939672.2939785.**
- Lundberg, S. M., & Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. Advances in Neural Information Processing Systems, 30.
- World Health Organization. (2021). WHO Global Air Quality Guidelines: particulate matter (PM2.5 and PM10), ozone, nitrogen dioxide, sulfur dioxide and carbon monoxide.
- Ajuntament de Barcelona. Open Data BCN. Portal de datos abiertos y datasets de calidad del aire, meteorología, tráfico, ruido y variables territoriales. <https://opendata-ajuntament.barcelona.cat/>
- Port de Barcelona. Open Data. Datos abiertos de actividad portuaria utilizados como contexto temporal. <https://opendata.portdebarcelona.cat/ca/dataset>
- Instituto Geográfico Nacional / Centro Nacional de Información Geográfica (IGN/CNIG). Modelo Digital del Terreno MDT200 – 1.ª cobertura, Barcelona, ETRS89/UTM huso 31. Centro de Descargas del CNIG.

Mapa de trazabilidad de entregables

Entregable	Función en el TFM
ANEXO_1_LF_01_ETL_Preprocesamiento_Fuentes.ipynb	ETL y control de calidad de contaminación, meteorología, tráfico rodado, ruido, tráfico aéreo y actividad marítima.
ANEXO_2_LF_02_ETL_Integracion_Dataset_Maestro.ipynb	Integración incremental y auditoría del dataset maestro temporal 43.642 × 73.
ANEXO_3_LF_03_Modelo_Temporal_Clasificacion_NO2.ipynb	Clasificación NO ₂ , XGBoost + SMOTE, TEST temporal, LOSO y SHAP.
ANEXO_4_LF_04_Modelos_Series_Temporales.ipynb	Series NO ₂ /PM10/PM2.5, Naive, SARIMA/SARIMAX, rolling y COVID/post-COVID.
ANEXO_5_LF_01_Preprocesado_Fuentes_Geospaciales.ipynb	Preprocesado de mapas de inmisión, renta, densidad, aforos, usos del suelo y MDT200 del CNIG/IGN.
ANEXO_6_LF_02_Integración_y_análisis_geoespacial.ipynb	LISA, Moran bivariado, OLS/SAR, XGBoost espacial y SHAP.
ANEXO_7_LF_01_Breathe_Barcelona_Dashboard.ipynb	Construcción y validación de Breathe Barcelona: Overview, Temporal, Spatial, Model Insights, Dual Predictor, Home, tema global y despliegue temporal.

Cierre de trazabilidad · La memoria sintetiza e interpreta; los anexos conservan el cálculo reproducible y GitHub facilita el acceso al código y su documentación.